

# Identification de mélanges gaussiens via des méthodes tensorielles

Vicnesh Venedittan encadré par Rima Khouja

2 Juin 2023

- Loi gaussienne multivariée

# Introduction

Identification de  
mélanges gaussiens  
via des méthodes  
tensorielles

Vicnesh  
Venedittan

- ▶ Loi gaussienne multivariée
- ▶ Modèle de mélange Gaussien

# Introduction

Identification de  
mélanges gaussiens  
via des méthodes  
tensorielles

Vicnesh  
Venedittan

- ▶ Loi gaussienne multivariée
- ▶ Modèle de mélange Gaussien
- ▶ Tenseur


## Definition

Soit  $X \in \mathbb{R}^n$  un vecteur aléatoire,  $X$  suit une distribution gaussienne multivariée de paramètre  $\mu \in \mathbb{R}^n$  et  $\Sigma \in \mathbb{R}^{n \times n}$  définie positive, s'il admet pour densité :

$$f(X, \mu, \Sigma) = \frac{1}{\sqrt{(2\pi)^n |\Sigma|}} \exp\left(-\frac{1}{2}(X - \mu)^t \Sigma^{-1} (X - \mu)\right)$$


# Exemple loi gaussienne multivariée

Loi gaussienne multidimensionnelle (3D)

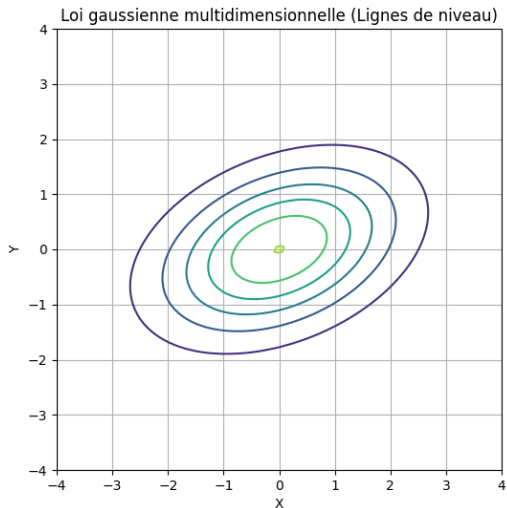


# Exemple loi gaussienne multivariée

Exemple de 10000 points générés



# Exemple loi gaussienne multivariée


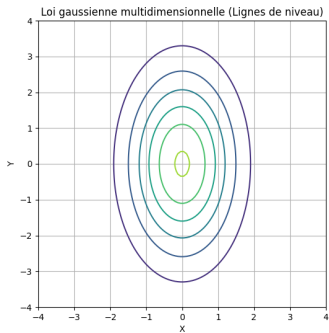




# Remarque

Identification de  
mélanges gaussiens  
via des méthodes  
tensorielles

Vicnesh  
Venedittan



## Definition

Soit  $\lambda = (\lambda_1, \dots, \lambda_m)$  tel que  $\sum_{i=1}^m \lambda_i = 1$ , puis  $\mu = (\mu_1, \dots, \mu_m)$  et  $\Sigma = (\Sigma_1, \dots, \Sigma_m)$ .  $X$  suit une loi de mélange gaussien à  $m$  composante de dimension  $p$  si elle admet pour densité :

$$f(X, \mu, \Sigma) = \sum_{i=1}^m \lambda_i f_i(X, \mu_i, \Sigma_i).$$

Où pour tout  $i \in 1, \dots, m$ ,  $f_i$  suit une loi gaussienne multivariée de paramètre  $(\mu_i, \Sigma_i)$ .

# Exemple de modèle de mélange gaussien

## Exemple


Pour  $\lambda = (0.3, 0.3, 0.4)$ ,  $\mu = \left( \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad \begin{pmatrix} 3 \\ 3 \end{pmatrix} \quad \begin{pmatrix} -3 \\ 3 \end{pmatrix} \right)$  et

$$\Sigma = \left( \begin{pmatrix} 1.5 & 0 \\ 0 & 1.5 \end{pmatrix} \quad \begin{pmatrix} 1.5 & 0 \\ 0 & 1.5 \end{pmatrix} \quad \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} \right).$$

# Lignes de niveaux

Identification de  
mélanges gaussiens  
via des méthodes  
tensorielles

Vicnesh  
Venedittan




# Représentation d'un mélange gaussien

Identification de  
mélanges gaussiens  
via des méthodes  
tensorielles

Vicnesh  
Venedittan


Exemple de 10000 points générés d'une mélange de trois gaussiens



# Représentation d'un mélange gaussien

Identification de  
mélanges gaussiens  
via des méthodes  
tensorielles

Vicnesh  
Venedittan



- Un problème d'identification d'un modèle de mélange revient à estimer le paramètre  $\theta = (\lambda, \mu, \Sigma)$

- ▶ Un problème d'identification d'un modèle de mélange revient à estimer le paramètre  $\theta = (\lambda, \mu, \Sigma)$
- ▶ Algorithme espérance-maximisation (EM)



- ▶ Un problème d'identification d'un modèle de mélange revient à estimer le paramètre  $\theta = (\lambda, \mu, \Sigma)$
- ▶ Algorithme espérance-maximisation (EM)
- ▶ Méthode itérative, on alterne deux étapes :

- ▶ Un problème d'identification d'un modèle de mélange revient à estimer le paramètre  $\theta = (\lambda, \mu, \Sigma)$
- ▶ Algorithme espérance-maximisation (EM)
- ▶ Méthode itérative, on alterne deux étapes :
  - ▶ Etape E : Calculer les valeurs manquantes dans le modèle en utilisant les données observées et les paramètres actuels du modèle

- ▶ Un problème d'identification d'un modèle de mélange revient à estimer le paramètre  $\theta = (\lambda, \mu, \Sigma)$
- ▶ Algorithme espérance-maximisation (EM)
- ▶ Méthode itérative, on alterne deux étapes :
  - ▶ Etape E : Calculer les valeurs manquantes dans le modèle en utilisant les données observées et les paramètres actuels du modèle
  - ▶ Etape M : on maximise la log-vraisemblance du modèle complété en ajustant les paramètres pour lesquels on a maintenant toutes les données.

- ▶ Un problème d'identification d'un modèle de mélange revient à estimer le paramètre  $\theta = (\lambda, \mu, \Sigma)$
- ▶ Algorithme espérance-maximisation (EM)
- ▶ Méthode itérative, on alterne deux étapes :
  - ▶ Etape E : Calculer les valeurs manquantes dans le modèle en utilisant les données observées et les paramètres actuels du modèle
  - ▶ Etape M : on maximise la log-vraisemblance du modèle complété en ajustant les paramètres pour lesquels on a maintenant toutes les données.
- ▶ Méthode des moments tensoriels

## Definition

Soit  $\mathbb{R}^{n_1} \otimes \dots \otimes \mathbb{R}^{n_d}$  l'espace vectoriel du produit tensoriel de  $\mathbb{R}^{n_1}, \dots, \mathbb{R}^{n_d}$  qu'on note  $\mathcal{T}_n^d$  avec  $n = (n_1, \dots, n_d)$ . Un tenseur  $\mathcal{T}$  de  $\mathcal{T}_n^d$  peut être représenté par un tableau multidimensionnel dans  $\mathbb{R}^{n_1 \times \dots \times n_d}$ , par rapport à une base fixe sur  $\mathbb{R}^{n_1}, \dots, \mathbb{R}^{n_d}$  avec  $\mathcal{T} = [t_{i_1, \dots, i_d}]_{1 \leq i_1 \leq n_1, \dots, 1 \leq i_d \leq n_d}$ , où  $t_{i_1, \dots, i_d} \in \mathbb{R}$  est l'élément  $(i_1, \dots, i_d)$  du tableau. Dans ce qui suit, on considère la base canonique sur  $\mathbb{R}^{n_1}, \dots, \mathbb{R}^{n_d}$ .

## Definition

Soit  $\mathbb{R}^{n_1} \otimes \dots \otimes \mathbb{R}^{n_d}$  l'espace vectoriel du produit tensoriel de  $\mathbb{R}^{n_1}, \dots, \mathbb{R}^{n_d}$  qu'on note  $\mathcal{T}_n^d$  avec  $n = (n_1, \dots, n_d)$ . Un tenseur  $\mathcal{T}$  de  $\mathcal{T}_n^d$  peut être représenté par un tableau multidimensionnel dans  $\mathbb{R}^{n_1 \times \dots \times n_d}$ , par rapport à une base fixe sur  $\mathbb{R}^{n_1}, \dots, \mathbb{R}^{n_d}$  avec  $\mathcal{T} = [t_{i_1, \dots, i_d}]_{1 \leq i_1 \leq n_1, \dots, 1 \leq i_d \leq n_d}$ , où  $t_{i_1, \dots, i_d} \in \mathbb{R}$  est l'élément  $(i_1, \dots, i_d)$  du tableau. Dans ce qui suit, on considère la base canonique sur  $\mathbb{R}^{n_1}, \dots, \mathbb{R}^{n_d}$ .

- En particuliers si  $n_1 = n_2 = \dots = n_d$  et  $t_{j_1, j_2, \dots, j_d} = t_{j_{\sigma(1)}, \dots, j_{\sigma(d)}}$ , pour tout  $\sigma \in \mathfrak{S}^d$ , des groupes de permutation de  $\{1, \dots, d\}$ , on dit alors que  $\mathcal{T}$  est un tenseur symétrique

## Definition

Soit  $\mathbb{R}^{n_1} \otimes \dots \otimes \mathbb{R}^{n_d}$  l'espace vectoriel du produit tensoriel de  $\mathbb{R}^{n_1}, \dots, \mathbb{R}^{n_d}$  qu'on note  $\mathcal{T}_n^d$  avec  $n = (n_1, \dots, n_d)$ . Un tenseur  $\mathcal{T}$  de  $\mathcal{T}_n^d$  peut être représenté par un tableau multidimensionnel dans  $\mathbb{R}^{n_1 \times \dots \times n_d}$ , par rapport à une base fixe sur  $\mathbb{R}^{n_1}, \dots, \mathbb{R}^{n_d}$  avec  $\mathcal{T} = [t_{i_1, \dots, i_d}]_{1 \leq i_1 \leq n_1, \dots, 1 \leq i_d \leq n_d}$ , où  $t_{i_1, \dots, i_d} \in \mathbb{R}$  est l'élément  $(i_1, \dots, i_d)$  du tableau. Dans ce qui suit, on considère la base canonique sur  $\mathbb{R}^{n_1}, \dots, \mathbb{R}^{n_d}$ .

- ▶ En particuliers si  $n_1 = n_2 = \dots = n_d$  et  $t_{j_1, j_2, \dots, j_d} = t_{j_{\sigma(1)}, \dots, j_{\sigma(d)}}$ , pour tout  $\sigma \in \mathfrak{S}^d$ , des groupes de permutation de  $\{1, \dots, d\}$ , on dit alors que  $\mathcal{T}$  est un tenseur symétrique
- ▶ On note  $\mathcal{S}_n^d$  l'espace des tenseurs symétriques d'ordre  $d$  de dimension  $n$ .

## Definition (Opération $Sym$ )

Pour tout  $\mathcal{A} \in \mathcal{T}_n^d$ ,  $(j_1, j_2, \dots, j_d) \in \{1, \dots, n\}^d$ :

$$Sym[\mathcal{A}](j_1, j_2, \dots, j_d) = \frac{1}{d!} \sum_{\sigma \in \mathfrak{S}^d} a_{j_{\sigma(1)}, \dots, j_{\sigma(d)}}.$$



## Definition (Produit scalaire tensoriel)

Soit  $\mathcal{A}, \mathcal{B} \in \mathcal{T}_n^d$ , on note le produit scalaire de  $\mathcal{A}$  et  $\mathcal{B}$  par :

$$\langle \mathcal{A}, \mathcal{B} \rangle = \sum_{i_1=1}^n \dots \sum_{i_d=1}^n a_{i_1, \dots, i_d} b_{i_1, \dots, i_d}.$$

► En particulier, on a :

$$\langle \mathcal{A}, \mathcal{A} \rangle = \|\mathcal{A}\|^2 = \sum_{i_1=1}^n \dots \sum_{i_d=1}^n a_{i_1, \dots, i_d}^2.$$

# Résumé de l'article : PEREIRA, KILEEL, KOLDA 2022

Identification de  
mélanges gaussiens  
via des méthodes  
tensorielles

Vicnesh  
Venedittan

- Identification de mélange gaussien par analyse tensorielle.

# Résumé de l'article : PEREIRA, KILEEL, KOLDA 2022

Identification de  
mélanges gaussiens  
via des méthodes  
tensorielles

Vicnesh  
Venedittan

- Identification de mélange gaussien par analyse tensorielle.
- Utiliser une méthode de moment.

# Résumé de l'article : PEREIRA, KILEEL, KOLDA 2022

Identification de  
mélanges gaussiens  
via des méthodes  
tensorielles

Vicnesh  
Venedittan

- Identification de mélange gaussien par analyse tensorielle.
- Utiliser une méthode de moment.
- Une nouvelle expression du moment d'ordre  $d$  tensoriel.

# Résumé de l'article : PEREIRA, KILEEL, KOLDA 2022

Identification de  
mélanges gaussiens  
via des méthodes  
tensorielles

Vicnesh  
Venedittan

- Identification de mélange gaussien par analyse tensorielle.
- Utiliser une méthode de moment.
- Une nouvelle expression du moment d'ordre  $d$  tensoriel.
- Transformer le problème d'identification en problème d'optimisation.

- On définit  $\Phi : \bigcup_{d=0}^{\infty} \mathcal{T}_n^d \rightarrow \bigcup_{d=0}^{\infty} \mathbb{R}[z_1, \dots, z_n]_d$  (l'ensemble des polynômes homogènes réels) tel que pour tout  $\mathcal{V} \in \mathcal{T}_n^d$  et  $z \in \mathbb{R}^n$

$$\Phi[\mathcal{V}](z) = \langle \mathcal{V}, z^{\otimes d} \rangle$$

- On définit  $\Phi : \bigcup_{d=0}^{\infty} \mathcal{T}_n^d \rightarrow \bigcup_{d=0}^{\infty} \mathbb{R}[z_1, \dots, z_n]_d$  (l'ensemble des polynômes homogènes réels) tel que pour tout  $\mathcal{V} \in \mathcal{T}_n^d$  et  $z \in \mathbb{R}^n$

$$\Phi[\mathcal{V}](z) = \langle \mathcal{V}, z^{\otimes d} \rangle$$

- L'application  $\Phi$  est une application linéaire bijective pour la restriction sur  $\mathcal{S}_n^d$ . Pour tout  $\mathcal{A} \in \mathcal{S}_n^d$ :

$$\Phi[\mathcal{A}] = \Phi[\text{Sym}(\mathcal{A})].$$

En particuliers si  $\mathcal{B} \in \mathcal{T}_n^d$ , et  $\Phi[\mathcal{A}] = \Phi[\mathcal{B}]$  alors  $\mathcal{A} = \text{Sym}[\mathcal{B}]$ .

- On définit  $\Phi : \bigcup_{d=0}^{\infty} \mathcal{T}_n^d \rightarrow \bigcup_{d=0}^{\infty} \mathbb{R}[z_1, \dots, z_n]_d$  (l'ensemble des polynômes homogènes réels) tel que pour tout  $\mathcal{V} \in \mathcal{T}_n^d$  et  $z \in \mathbb{R}^n$

$$\Phi[\mathcal{V}](z) = \langle \mathcal{V}, z^{\otimes d} \rangle$$

- L'application  $\Phi$  est une application linéaire bijective pour la restriction sur  $\mathcal{S}_n^d$ . Pour tout  $\mathcal{A} \in \mathcal{S}_n^d$ :

$$\Phi[\mathcal{A}] = \Phi[\text{Sym}(\mathcal{A})].$$

En particuliers si  $\mathcal{B} \in \mathcal{T}_n^d$ , et  $\Phi[\mathcal{A}] = \Phi[\mathcal{B}]$  alors  $\mathcal{A} = \text{Sym}[\mathcal{B}]$ .

- Pour tout vecteur  $v \in \mathbb{R}^n$  et pour toutes matrices  $M \in \mathbb{R}^{n \times n}$ , les polynômes homogènes  $\Phi[v]$ ,  $\Phi[M]$  s'écrivent :

$$\Phi[v](z) = v^T z \text{ et } \Phi[M](z) = z^T M z.$$



## Résumé de l'article

- On définit  $\Phi : \bigcup_{d=0}^{\infty} \mathcal{T}_n^d \rightarrow \bigcup_{d=0}^{\infty} \mathbb{R}[z_1, \dots, z_n]_d$  (l'ensemble des polynômes homogènes réels) tel que pour tout  $\mathcal{V} \in \mathcal{T}_n^d$  et  $z \in \mathbb{R}^n$

$$\Phi[\mathcal{V}](z) = \langle \mathcal{V}, z^{\otimes d} \rangle$$

- L'application  $\Phi$  est une application linéaire bijective pour la restriction sur  $\mathcal{S}_n^d$ . Pour tout  $\mathcal{A} \in \mathcal{S}_n^d$ :

$$\Phi[\mathcal{A}] = \Phi[\text{Sym}(\mathcal{A})].$$

En particuliers si  $\mathcal{B} \in \mathcal{T}_n^d$ , et  $\Phi[\mathcal{A}] = \Phi[\mathcal{B}]$  alors  $\mathcal{A} = \text{Sym}[\mathcal{B}]$ .

- Pour tout vecteur  $v \in \mathbb{R}^n$  et pour toutes matrices  $M \in \mathbb{R}^{n \times n}$ , les polynômes homogènes  $\Phi[v]$ ,  $\Phi[M]$  s'écrivent :

$$\Phi[v](z) = v^T z \text{ et } \Phi[M](z) = z^T M z.$$

- Pour tout  $\mathcal{A} \in \mathcal{T}_n^{d_1}$ ,  $\mathcal{B} \in \mathcal{T}_n^{d_2}$ , on a :

$$\Phi[\mathcal{A} \otimes \mathcal{B}] = \Phi[\mathcal{A}]\Phi[\mathcal{B}].$$

## Théorème 1 : Pereira, Kileel, Kolda, 2022

Soit  $X \sim \mathcal{N}(\mu, \Sigma)$ , le moment d'ordre  $d$  de  $X$  est  $\mathcal{M}^{(d)} = \mathbb{E}(X^{\otimes d})$  plus précisément :

$$\mathcal{M}^{(d)} = \sum_{k=0}^{\lfloor d/2 \rfloor} C_{d,k} \text{Sym}(\mu^{\otimes d-2k} \otimes \Sigma^{\otimes k}),$$

avec :  $C_{d,k} = \binom{d}{2k} \frac{2k!}{k! 2^k}$ .

## Théorème 2 : Pereira, Kileel, Kolda, 2022

Si  $X \sim \sum_{j=1}^m \lambda_j \mathcal{N}(\mu_j, \Sigma_j)$ , le moment d'ordre  $d$  de  $X$  est  $\mathcal{M}^{(d)} = \mathbb{E}(X^{\otimes d})$  plus précisément :

$$\mathcal{M}^{(d)} = \sum_{j=1}^m \sum_{k=0}^{\lfloor d/2 \rfloor} \lambda_j C_{d,k} \text{Sym}(\mu^{\otimes d-2k} \otimes \Sigma^{\otimes k}),$$

avec :  $C_{d,k} = \binom{d}{2k} \frac{2k!}{k! 2^k}$ .

# La méthode du moment proposée

- On considère un échantillon  $(x_1, \dots, x_p)$  de réalisation d'un mélange gaussien de paramètre  $\theta = (\lambda, \mu, \Sigma)$

# La méthode du moment proposée

- ▶ On considère un échantillon  $(x_1, \dots, x_p)$  de réalisation d'un mélange gaussien de paramètre  $\theta = (\lambda, \mu, \Sigma)$
- ▶ On veut estimer le paramètre  $\theta = (\lambda, \mu, \Sigma)$

# La méthode du moment proposée

- ▶ On considère un échantillon  $(x_1, \dots, x_p)$  de réalisation d'un mélange gaussien de paramètre  $\theta = (\lambda, \mu, \Sigma)$
- ▶ On veut estimer le paramètre  $\theta = (\lambda, \mu, \Sigma)$
- ▶ On veut approcher le moment empirique  $\frac{1}{p} \sum_{i=1}^p x_i^{\otimes d}$  et le moment théorique  $\mathcal{M}^{(d)}$ , cela revient à résoudre le problème d'optimisation

# La méthode du moment proposée

- ▶ On considère un échantillon  $(x_1, \dots, x_p)$  de réalisation d'un mélange gaussien de paramètre  $\theta = (\lambda, \mu, \Sigma)$
- ▶ On veut estimer le paramètre  $\theta = (\lambda, \mu, \Sigma)$
- ▶ On veut approcher le moment empirique  $\frac{1}{p} \sum_{i=1}^p x_i^{\otimes d}$  et le moment théorique  $\mathcal{M}^{(d)}$ , cela revient à résoudre le problème d'optimisation

$$\min_{\theta} F(\theta) = \left\| \mathcal{M}^{(d)} - \frac{1}{p} \sum_{i=1}^p x_i^{\otimes d} \right\|^2$$

# La méthode du moment proposée

$$\blacktriangleright F(\theta) = \left\| \mathcal{M}^{(d)} - \frac{1}{p} \sum_{i=1}^p x_i^{\otimes d} \right\|^2 =$$



# La méthode du moment proposée

- $F(\theta) = \|\mathcal{M}^{(d)} - \frac{1}{p} \sum_{i=1}^p x_i^{\otimes d}\|^2 =$
- $\|\mathcal{M}^{(d)}\|^2 - 2 \times \frac{1}{p} \sum_{i=1}^p \langle \mathcal{M}^{(d)}, x_i^{\otimes d} \rangle$

# La méthode du moment proposée

- $F(\theta) = \|\mathcal{M}^{(d)} - \frac{1}{p} \sum_{i=1}^p x_i^{\otimes d}\|^2 =$
- $\|\mathcal{M}^{(d)}\|^2 - 2 \times \frac{1}{p} \sum_{i=1}^p \langle \mathcal{M}^{(d)}, x_i^{\otimes d} \rangle$
- $F_1(\theta) = \|\mathcal{M}^{(d)}\|^2$  et  $F_2(\theta) = \frac{1}{p} \sum_{i=1}^p \langle \mathcal{M}^{(d)}, x_i^{\otimes d} \rangle$

# La méthode du moment proposée

- ▶ Après avoir décomposé notre problème d'optimisation en 2 problèmes d'optimisation plus simple, nous allons calculer le gradient de  $F_1$  et de  $F_2$ .

# La méthode du moment proposée

- ▶ Après avoir décomposé notre problème d'optimisation en 2 problèmes d'optimisation plus simple, nous allons calculer le gradient de  $F_1$  et de  $F_2$ .
- ▶ L'article propose une expression des gradients explicites en fonction de  $\theta$ .

# La méthode du moment proposée

- ▶ Après avoir décomposé notre problème d'optimisation en 2 problèmes d'optimisation plus simple, nous allons calculer le gradient de  $F_1$  et de  $F_2$ .
- ▶ L'article propose une expression des gradients explicites en fonction de  $\theta$ .
- ▶ Ces gradients peuvent être utilisé pour implémenter n'importe quelle méthode du 1er ordre de gradient.

- ▶ Après avoir décomposé notre problème d'optimisation en 2 problèmes d'optimisation plus simple, nous allons calculer le gradient de  $F_1$  et de  $F_2$ .
- ▶ L'article propose une expression des gradients explicites en fonction de  $\theta$ .
- ▶ Ces gradients peuvent être utilisé pour implémenter n'importe quelle méthode du 1er ordre de gradient.
- ▶ On choisit la méthode du gradient à pas fixe.

## Méthode du gradient à pas fixe

On se donne un point initial  $x_0$  et un seuil de tolérance  $\epsilon > 0$ . L'algorithme du gradient à pas fixe  $\alpha$ . L'itération  $k + 1$  est donné par :

- ▶ Calcul de :  $\nabla f(x_k)$
- ▶ Test d'arrêt :  $\|\nabla f(x_k)\| < \epsilon$
- ▶ Nouvelle itération :  $x_{k+1} = x_k - \alpha \nabla f(x_k)$


## Exemple

On initialise notre paramètre  $\theta$  avec :

$$\lambda = (0.5, 0.2, 0.3), \mu = \left( \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad \begin{pmatrix} 3 \\ 3 \end{pmatrix} \quad \begin{pmatrix} -5 \\ 5 \end{pmatrix} \right)$$


$$\Sigma = \left( \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \quad \begin{pmatrix} 0.5 & 0 \\ 0 & 0.5 \end{pmatrix} \quad \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} \right).$$

Exemple de 10000 points générés d'une mélange de trois gaussiens







Steepest descent gradient method applied on  $F_1(d=1)$  with step size  $1.e-3$




Steepest descent gradient method applied on F1(d=2) with step size  $1.e-3$




Steepest descent gradient method applied on F1(d=3) with step size  $1.e-6$




Steepest descent gradient method applied on  $F(d=1)$  with step size  $1.e-5$



Steepest descent gradient method applied on  $F(d=2)$  with step size  $1.e-7$



Steepest descent gradient method applied on  $F(d=3)$  with step size  $1.e-9$



# Conclusion

- Dans l'optique d'estimer le paramètre d'un modèle de mélange gaussien, les méthodes les plus utilisées sont :

# Conclusion

- ▶ Dans l'optique d'estimer le paramètre d'un modèle de mélange gaussien, les méthodes les plus utilisées sont :
- ▶ l'algorithme EM et la méthode des moments



- ▶ Dans l'optique d'estimer le paramètre d'un modèle de mélange gaussien, les méthodes les plus utilisées sont :
- ▶ l'algorithme EM et la méthode des moments
- ▶ L'article résumé, présente une méthode algorithmique pour estimer le paramètre revenant alors à un problème d'optimisation.

- ▶ Dans l'optique d'estimer le paramètre d'un modèle de mélange gaussien, les méthodes les plus utilisées sont :
- ▶ l'algorithme EM et la méthode des moments
- ▶ L'article résumé, présente une méthode algorithmique pour estimer le paramètre revenant alors à un problème d'optimisation.
- ▶ En générant un jeu de données de paramètre  $\theta$  d'un modèle de mélange gaussien, on valide expérimentalement les calculs de cet article avec une méthode du gradient à pas fixe.

Merci pour votre attention !